微调到底有没有用？让同一图库说话

先对齐评测口径，再讨论提升来自哪里。

4,500 / 1,000 / 2,000
训练 / 验证 / 测试图片

8 组配置 · 24 个验证检查点
模型与阈值只在验证集选

A / Qwen LoRA

统一 JSON 结构归一化后的补充对照；非新盲测

检索 F1	基座		微调	提升 / 百分点
文搜图	76.07%	→	**86.76%**	**+10.69**
图搜图	63.90%	→	**81.86%**	**+17.96**

B / Embedding 对比学习

原始固定协议；直接编码原图，不经过 Qwen 类别筛选

检索 F1	基座		微调	提升 / 百分点
文搜图	61.68%	→	**88.84%**	**+27.16**
图搜图	31.85%	→	**83.40%**	**+51.55**

涨点之外，我还追查了原因

Qwen 的差距包含格式适配，不能全部算成视觉能力。

共用类别筛选、只换描述向量：+2.48 / +0.01 个百分点。

在这组类别检索实验中，主要收益集中在类别筛选。

范围：15 类候选图库，报告五个重点类别的平均 F1。

两组协议分别解读；单随机种子，不代表细粒度或同款匹配。

来源：docs/study/comparison.csv · docs/QWEN_CONTROLS.md

先跑通，再换数据
最后训练自己的模型

从看得见的结果，走到可解释的实验。

1 打开演示 / 无需 GPU

下载仓库，在项目根目录执行；只需 Python 3.10+

```
python3 examples/quickstart.py
```

这是已记录结果的回放；不是实时模型推理。

2 换自己的图片 / 真正跑检索

有模型运行环境后，先用仓库里的 12 张示例图体验

准备图片与清单 → 建索引 → 输入查询

公开配置使用基座；微调权重尚未分发。

3 做训练 / 比较两条技术路线

先划分训练、验证、测试，再构建监督样本

Qwen LoRA × Embedding InfoNCE

验证集选参数，固定测试集报告 F1 / mAP。

代码、数据接入、训练指南都在这里

GitHub 搜索：

liangjianshu

multimodal-image-retrieval

阅读顺序：QUICKSTART → ARCHITECTURE → TRAINING